

山东大学 计算机科学与技术 学院

大数据分析实践 课程实验报告

学号：202300130281	姓名：马小强	班级：数据班																																																																																																																																																																																																						
实验题目：数据采集方法实践																																																																																																																																																																																																								
实验学时：2	实验日期：2025/9/19																																																																																																																																																																																																							
实验目的： 本实验旨在通过Python 的Pandas 库，系统地学习和实践多种数据采集与过滤方法，全面提升数据 处理能力。首先，在数据预处理方面，实验着重培养处理原始数据中缺失值和异常值的技能，能够 有效识别和清理数据质量问题，为后续分析提供干净、完整的数据基础。其次，在数据过滤技术层 面，实验训练掌握基于多条件组合的数据筛选方法，能够根据具体分析需求精准提取目标数据子集。 在采样方法实现方面，实验涵盖多种重要采样技术的实践，包括加权采样、随机抽样、分层抽样、 系统抽样和整群抽样等，深入理解各种采样方法的原理、适用场景和实现细节。通过采样效果对比 分析环节，学会评估不同采样方法的结果差异，分析各种方法对数据分布特征的影响，并能够根据 具体应用场景选择最合适的采样策略。																																																																																																																																																																																																								
硬件环境： 计算机一台																																																																																																																																																																																																								
软件环境： Linux 或 Windows																																																																																																																																																																																																								
实验步骤与内容： 1. 库导入与数据读入：导入 pandas、numpy 库，通过 pd.read_csv 读取指定数据集，查看 数据结构（含 1147 行 10 列，底部有较多空行）。 2. 数据清洗与过滤：用 dropna(how='any') 删除空行；先过滤出 traffic 不等于 0 的数据， 再筛选 from_level 为 “一般节点” 的数据。																																																																																																																																																																																																								
原始数据： <table><tr><th></th><th>from_dev</th><th>from_port</th><th>from_city</th><th>from_level</th><th>to_dev</th><th>to_port</th><th>to_city</th><th>to_level</th><th>traffic</th><th>bandwidth</th></tr><tr><td>0</td><td>47</td><td>71</td><td>通辽</td><td>一般节点</td><td>1756</td><td>585</td><td>北京</td><td>网络核心</td><td>49636052613</td><td>1.000000e+11</td></tr><tr><td>1</td><td>47</td><td>74</td><td>通辽</td><td>一般节点</td><td>1756</td><td>776</td><td>北京</td><td>网络核心</td><td>50056871412</td><td>1.000000e+11</td></tr><tr><td>2</td><td>47</td><td>240</td><td>通辽</td><td>一般节点</td><td>1756</td><td>802</td><td>北京</td><td>网络核心</td><td>49453581081</td><td>1.000000e+11</td></tr><tr><td>3</td><td>47</td><td>241</td><td>通辽</td><td>一般节点</td><td>1997</td><td>464</td><td>天津</td><td>网络核心</td><td>49733361585</td><td>1.000000e+11</td></tr><tr><td>4</td><td>47</td><td>242</td><td>通辽</td><td>一般节点</td><td>474</td><td>672</td><td>哈尔滨</td><td>一般节点</td><td>50492573662</td><td>1.000000e+11</td></tr></table> 删除空行后： <table><tr><th></th><th>from_dev</th><th>from_port</th><th>from_city</th><th>from_level</th><th>to_dev</th><th>to_port</th><th>to_city</th><th>to_level</th><th>traffic</th><th>bandwidth</th></tr><tr><td>0</td><td>47</td><td>71</td><td>通辽</td><td>一般节点</td><td>1756</td><td>585</td><td>北京</td><td>网络核心</td><td>49636052613</td><td>1.000000e+11</td></tr><tr><td>1</td><td>47</td><td>74</td><td>通辽</td><td>一般节点</td><td>1756</td><td>776</td><td>北京</td><td>网络核心</td><td>50056871412</td><td>1.000000e+11</td></tr><tr><td>2</td><td>47</td><td>240</td><td>通辽</td><td>一般节点</td><td>1756</td><td>802</td><td>北京</td><td>网络核心</td><td>49453581081</td><td>1.000000e+11</td></tr><tr><td>3</td><td>47</td><td>241</td><td>通辽</td><td>一般节点</td><td>1997</td><td>464</td><td>天津</td><td>网络核心</td><td>49733361585</td><td>1.000000e+11</td></tr><tr><td>4</td><td>47</td><td>242</td><td>通辽</td><td>一般节点</td><td>474</td><td>672</td><td>哈尔滨</td><td>一般节点</td><td>50492573662</td><td>1.000000e+11</td></tr></table> 过滤后数据： <table><tr><th></th><th>from_dev</th><th>from_port</th><th>from_city</th><th>from_level</th><th>to_dev</th><th>to_port</th><th>to_city</th><th>to_level</th><th>traffic</th><th>bandwidth</th></tr><tr><td>0</td><td>47</td><td>71</td><td>通辽</td><td>一般节点</td><td>1756</td><td>585</td><td>北京</td><td>网络核心</td><td>49636052613</td><td>1.000000e+11</td></tr><tr><td>1</td><td>47</td><td>74</td><td>通辽</td><td>一般节点</td><td>1756</td><td>776</td><td>北京</td><td>网络核心</td><td>50056871412</td><td>1.000000e+11</td></tr><tr><td>2</td><td>47</td><td>240</td><td>通辽</td><td>一般节点</td><td>1756</td><td>802</td><td>北京</td><td>网络核心</td><td>49453581081</td><td>1.000000e+11</td></tr><tr><td>3</td><td>47</td><td>241</td><td>通辽</td><td>一般节点</td><td>1997</td><td>464</td><td>天津</td><td>网络核心</td><td>49733361585</td><td>1.000000e+11</td></tr><tr><td>4</td><td>47</td><td>242</td><td>通辽</td><td>一般节点</td><td>474</td><td>672</td><td>哈尔滨</td><td>一般节点</td><td>50492573662</td><td>1.000000e+11</td></tr></table>				from_dev	from_port	from_city	from_level	to_dev	to_port	to_city	to_level	traffic	bandwidth	0	47	71	通辽	一般节点	1756	585	北京	网络核心	49636052613	1.000000e+11	1	47	74	通辽	一般节点	1756	776	北京	网络核心	50056871412	1.000000e+11	2	47	240	通辽	一般节点	1756	802	北京	网络核心	49453581081	1.000000e+11	3	47	241	通辽	一般节点	1997	464	天津	网络核心	49733361585	1.000000e+11	4	47	242	通辽	一般节点	474	672	哈尔滨	一般节点	50492573662	1.000000e+11		from_dev	from_port	from_city	from_level	to_dev	to_port	to_city	to_level	traffic	bandwidth	0	47	71	通辽	一般节点	1756	585	北京	网络核心	49636052613	1.000000e+11	1	47	74	通辽	一般节点	1756	776	北京	网络核心	50056871412	1.000000e+11	2	47	240	通辽	一般节点	1756	802	北京	网络核心	49453581081	1.000000e+11	3	47	241	通辽	一般节点	1997	464	天津	网络核心	49733361585	1.000000e+11	4	47	242	通辽	一般节点	474	672	哈尔滨	一般节点	50492573662	1.000000e+11		from_dev	from_port	from_city	from_level	to_dev	to_port	to_city	to_level	traffic	bandwidth	0	47	71	通辽	一般节点	1756	585	北京	网络核心	49636052613	1.000000e+11	1	47	74	通辽	一般节点	1756	776	北京	网络核心	50056871412	1.000000e+11	2	47	240	通辽	一般节点	1756	802	北京	网络核心	49453581081	1.000000e+11	3	47	241	通辽	一般节点	1997	464	天津	网络核心	49733361585	1.000000e+11	4	47	242	通辽	一般节点	474	672	哈尔滨	一般节点	50492573662	1.000000e+11
	from_dev	from_port	from_city	from_level	to_dev	to_port	to_city	to_level	traffic	bandwidth																																																																																																																																																																																														
0	47	71	通辽	一般节点	1756	585	北京	网络核心	49636052613	1.000000e+11																																																																																																																																																																																														
1	47	74	通辽	一般节点	1756	776	北京	网络核心	50056871412	1.000000e+11																																																																																																																																																																																														
2	47	240	通辽	一般节点	1756	802	北京	网络核心	49453581081	1.000000e+11																																																																																																																																																																																														
3	47	241	通辽	一般节点	1997	464	天津	网络核心	49733361585	1.000000e+11																																																																																																																																																																																														
4	47	242	通辽	一般节点	474	672	哈尔滨	一般节点	50492573662	1.000000e+11																																																																																																																																																																																														
	from_dev	from_port	from_city	from_level	to_dev	to_port	to_city	to_level	traffic	bandwidth																																																																																																																																																																																														
0	47	71	通辽	一般节点	1756	585	北京	网络核心	49636052613	1.000000e+11																																																																																																																																																																																														
1	47	74	通辽	一般节点	1756	776	北京	网络核心	50056871412	1.000000e+11																																																																																																																																																																																														
2	47	240	通辽	一般节点	1756	802	北京	网络核心	49453581081	1.000000e+11																																																																																																																																																																																														
3	47	241	通辽	一般节点	1997	464	天津	网络核心	49733361585	1.000000e+11																																																																																																																																																																																														
4	47	242	通辽	一般节点	474	672	哈尔滨	一般节点	50492573662	1.000000e+11																																																																																																																																																																																														
	from_dev	from_port	from_city	from_level	to_dev	to_port	to_city	to_level	traffic	bandwidth																																																																																																																																																																																														
0	47	71	通辽	一般节点	1756	585	北京	网络核心	49636052613	1.000000e+11																																																																																																																																																																																														
1	47	74	通辽	一般节点	1756	776	北京	网络核心	50056871412	1.000000e+11																																																																																																																																																																																														
2	47	240	通辽	一般节点	1756	802	北京	网络核心	49453581081	1.000000e+11																																																																																																																																																																																														
3	47	241	通辽	一般节点	1997	464	天津	网络核心	49733361585	1.000000e+11																																																																																																																																																																																														
4	47	242	通辽	一般节点	474	672	哈尔滨	一般节点	50492573662	1.000000e+11																																																																																																																																																																																														
3. 多种采样实现：分别进行加权采样(to_level 为一般节点与网络核心权重 1:5, 抽 50 个																																																																																																																																																																																																								

样本)、随机采样(直接抽 50 个样本)、分层采样(一般节点抽 17 个、网络核心抽 33 个, 合并样本), 也可自行实现系统抽样、整群抽样

加权采样结果:

	from_dev	from_port	from_city	from_level	to_dev	to_port	to_city	to_level	traffic	bandwidth
170	787	60	玉溪	一般节点	4561	1025	成都	网络核心	49992676292	1.000000e+11
654	47	417	通辽	一般节点	36422	394	天津	网络核心	50110808318	1.000000e+11
888	36036	20	长春	一般节点	1997	85	天津	网络核心	48987594976	1.000000e+11
443	787	52	玉溪	一般节点	2360	215	太原	网络核心	49322809158	1.000000e+11
121	474	1269	哈尔滨	一般节点	2549	1430	沈阳	网络核心	50312177853	1.000000e+11

随机抽样结果:

	from_dev	from_port	from_city	from_level	to_dev	to_port	to_city	to_level	traffic	bandwidth
177	787	325	玉溪	一般节点	4561	1087	成都	网络核心	48864832885	1.000000e+11
2	47	240	通辽	一般节点	1756	802	北京	网络核心	49453581081	1.000000e+11
85	180	218	呼和浩特	一般节点	3443	650	青岛	网络核心	50106572586	1.000000e+11
836	180	20	呼和浩特	一般节点	591	27	绥化	一般节点	49701796126	1.000000e+11
448	787	307	玉溪	一般节点	36422	258	天津	网络核心	51727332383	1.000000e+11

分层抽样结果:

	from_dev	from_port	from_city	from_level	to_dev	to_port	to_city	to_level	traffic	bandwidth
762	474	1374	哈尔滨	一般节点	180	18	呼和浩特	一般节点	48043608658	1.000000e+11
444	787	54	玉溪	一般节点	474	422	哈尔滨	一般节点	50571503467	1.000000e+11
1104	63	6	通辽	一般节点	36036	20	长春	一般节点	50355678076	1.000000e+11
966	36539	1146	杭州	一般节点	63	12	通辽	一般节点	49520418698	1.000000e+11
787	36036	54	长春	一般节点	180	256	呼和浩特	一般节点	51915256521	1.000000e+11

结论分析与体会:

深刻理解了 Pandas 库中 dropna、loc、sample 等函数的实际应用, 将数据清洗、过滤、采样的理论知识转化为可操作的代码, 掌握了数据预处理的完整流程。不同采样方法的适用场景不同, 需根据分析目标灵活选择。