

山东大学 计算机科学与技术 学院

大数据分析实践 课程实验报告

学号：202300130281	姓名：马小强	班级：数据班
实验题目：基于 BERT 的 MRPC 同义句预测		
实验学时：2	实验日期：2025/11/17	
实验目的： 利用预训练的 transformers 的预训练 BERT 模型对 MRPC 数据集进行同义预测的 pipeline. MRPC 包含了 5800 个句子对，有的是同义的，有的是不同义的，是否同义由一个二元标签进行描述.		
硬件环境： 计算机一台		
软件环境： Linux 或 Windows		
实验步骤与内容： 1. 环境配置：搭建含 GPU（CUDA≥10.0）的远程服务器环境，安装 Anaconda、Python3.x，创建虚拟环境并安装 torch==1.7.0、transformers==4.18.0 等依赖包。 2. 数据与模型准备：下载 MRPC 数据集并整理为训练 / 测试 CSV 文件，确保含句子对及标签列；下载 bert-base-uncased 模型文件（config.json、pytorch_model.bin、vocab.txt）并存放至指定路径。 3. 代码部署：将 FCModel.py（全连接分类模型）、MRPCDataset.py（数据集加载类）、main.py（训练测试主程序）上传至服务器，配置数据集路径与模型路径。 4. 模型训练：运行 main.py，加载数据集与 BERT 模型，设置 batch_size=16、num_epochs=3 等参数，通过 Adam 优化器训练，每轮记录训练 / 测试损失与准确率，保存最佳模型。 5. 模型评估：训练完成后，用测试集评估最终模型性能，输出测试损失与准确率，验证模型同义句预测效果 Epoch 1/3: Train Loss: 0.5640, Train Acc: 0.7174 Test Loss: 0.5333, Test Acc: 0.7003 Time: 862.46s ✅ 保存最佳模型，测试准确率: 0.7003 Epoch 2/3: Train Loss: 0.4484, Train Acc: 0.7949 Test Loss: 0.4508, Test Acc: 0.7681 Time: 865.37s ✅ 保存最佳模型，测试准确率: 0.7681		

```
Epoch 3/3:
  Train Loss: 0.3710, Train Acc: 0.8457
  Test Loss: 0.4410, Test Acc: 0.8017
  Time: 869.14s
  ✅ 保存最佳模型，测试准确率: 0.8017
```

```
训练完成！最佳测试准确率: 0.8017

=== 最终模型测试 ===
Eval Batch 0: Loss = 0.2789, Accuracy = 0.9375
Be aware, overflowing tokens are not returned for the setting you chose.
Be aware, overflowing tokens are not returned for the setting you chose.
Be aware, overflowing tokens are not returned for the setting you chose.
Be aware, overflowing tokens are not returned for the setting you chose.
Be aware, overflowing tokens are not returned for the setting you chose.
Eval Batch 100: Loss = 0.3078, Accuracy = 0.7500
最终测试结果 - Loss: 0.4410, Accuracy: 0.8017
```

Epoch-by-Epoch 进步:

Epoch	训练准确率	测试准确率	提升幅度
Epoch 1	71.74%	70.03%	基准
Epoch 2	79.49%	76.81%	+6.78%
Epoch 3	84.57%	80.17%	+3.36%

结论分析与体会:

深刻掌握了 PyTorch+Transformers 框架的实战流程，理解了预训练模型微调的核心逻辑；学会了数据集封装、模型训练与评估的完整链路设计，认识到超参数设置（如学习率、batch_size）对模型性能的关键影响，提升了大规模文本数据处理和远程 GPU 环境调试能力。