

山东大学__ 计算机科学与技术 __学院

大数据分析实践 课程实验报告

学号： 202300130059	姓名：林子洋	班级：数据
实验题目：数据采样方法实践		
实验学时：2	实验日期：2025.9.30	
实验要求：利用 Pandas 库实现多种数据采样和过滤的方法		
硬件环境： 计算机一台		
软件环境： 编程语言：Python 3.9 开发工具：Jupyter Notebook 核心库：Pandas、NumPy		
实验步骤与内容： 环境准备：导入 Pandas、NumPy 库，读取数据集。 数据清洗：删除空行，过滤出 traffic≠0 且 from_level=一般节点的有效数据。 采样实践：基于清洗后的数据，实现 4 种采样方法（加权、随机、分层、系统抽样），各抽取 50 个样本。		

结果对比：观察不同采样方法的样本分布差异，分析适用场景。

实验代码如下：

1. 导入库并读取数据

```
import pandas as pd
```

```
import numpy as np
```

读取数据集（若本地文件名为 data.csv，或替换为实际路径）

```
primitive_data = pd.read_csv("data.csv")
```

```
print("原始数据预览：")
```

```
display(primitive_data.head()) # 显示前 5 行
```

2. 数据清洗：删除空行+条件过滤

2.1 删除所有空行

```
primitive_data_1 = primitive_data.dropna(how='any')
```

```
print("\n 删除空行后的数据量：", len(primitive_data_1))
```

2.2 过滤 traffic≠0 且 from_level=一般节点的数据

```
data_after_filter_1 =
```

```
primitive_data_1.loc[primitive_data_1["traffic"] != 0]
```

```
data_after_filter_2 =
```

```
data_after_filter_1.loc[data_after_filter_1["from_level"] == '一般节点']

print("过滤后的数据量: ", len(data_after_filter_2))

print("过滤后的数据预览: ")

display(data_after_filter_2.head())
```

3. 多种采样方法实现（均抽取 50 个样本）

```
data_before_sample = data_after_filter_2 # 采样数据源
columns = data_before_sample.columns      # 保留原始列名
```

3.1 加权采样（to_level=一般节点:网络核心=1:5）

```
weight_sample = data_before_sample.copy()
weight_sample['weight'] = np.where(weight_sample['to_level']
== '一般节点', 1, 5) # 简化权重赋值
weight_sample_finish = weight_sample.sample(n=50,
weights='weight')[columns] # 按权重采样并保留原始列
print("\n 加权采样结果（前 5 行）: ")
display(weight_sample_finish.head())
```

3.2 随机采样

```
random_sample_finish = data_before_sample.sample(n=50)
```

```
print("\n 随机采样结果（前 5 行）： ")
display(random_sample_finish.head())
```

3.3 分层采样（一般节点 17 个，网络核心 33 个）

```
ybjd = data_before_sample.loc[data_before_sample['to_level']
== '一般节点'] # 分层 1：一般节点
wlhx = data_before_sample.loc[data_before_sample['to_level']
== '网络核心'] # 分层 2：网络核心
stratified_sample = pd.concat([ybjd.sample(17),
wlhx.sample(33)]) # 合并分层样本
print("\n 分层采样结果（前 5 行）： ")
display(stratified_sample.head())
```

3.4 系统抽样（按固定间隔采样）

```
systematic_data = data_before_sample.reset_index(drop=True)
# 重置索引，保证有序
k = max(1, len(systematic_data) // 50) # 计算间隔（避免除数为 0）
systematic_sample = systematic_data.iloc[::k].head(50) # 按间隔抽样，取前 50 个
print("\n 系统抽样结果（前 5 行）： ")
display(systematic_sample.head())
```

结论分析与体会：

实验结论

数据清洗的必要性：原始数据中的空行和无效值会影响后续分析，通过 `dropna` 和条件过滤可显著提升数据质量。

采样方法对比：

加权采样：可通过权重控制特定类别样本的占比，适用于需要突出重要类别的场景（如“网络核心”节点分析）。

随机采样：操作简单，无偏性好，但无法控制样本类别比例，适用于对分布无特殊要求的场景。

分层抽样：能精确控制各层样本量，保证层内代表性，适用于类别不平衡数据（如“网络核心”样本占比过高 / 过低时）。

系统抽样：样本分布均匀，适用于有序数据，但依赖数据排序方式，可能引入潜在偏差。

实验体会

Pandas 库为数据预处理提供了强大工具，`dropna`、`loc`、`sample` 等方法可高效实现清洗和采样，大幅提升数据处理效率。

采样方法的选择需结合业务场景：若需突出关键类别，优先用加权采样；若需保证各层代表性，优先用分层抽样；通用场景下随机抽样更便捷。

数据预处理是数据分析的基础，清洗和采样的质量直接影响后续建模或分析结果的可靠性，需谨慎选择方法并验证效果。